1. Wstęp

Grupowanie, znane również jako **analiza skupień lub klasteryzacja**, to technika eksploracji danych należąca do metod klasyfikacji bez nadzoru. Jej celem jest podział zbioru danych na podzbiory (klastry), których elementy są wewnętrznie podobne, a jednocześnie wyraźnie różne od elementów innych grup. Grupowanie umożliwia odkrywanie ukrytej struktury w danych oraz ich uogólnianie.

W ramach projektu zostanie przeprowadzona analiza skupień z wykorzystaniem metod grupowania, mająca na celu identyfikację jednorodnych grup obserwacji.

2. Opis wybranego zbioru danych

Zbiór danych dotyczy **600 gospodarstw domowych z Indii** i został zebrany przez agencję badawczą CRISA w ramach badania rynku **mydła** toaletowego. Każdy wiersz reprezentuje jedno gospodarstwo, a dane zawierają zarówno informacje demograficzne, jak i szczegółowe wskaźniki dotyczące zachowań zakupowych.

Dane obejmują trzy główne grupy zmiennych:

- **demograficzne** (klasa społeczno-ekonomiczna, nawyki żywieniowe, płeć, wiek i wykształcenie osoby prowadzącej dom, liczba członków gospodarstwa domowego, obecność dzieci, wskaźnik zamożności oparty na posiadaniu dóbr trwałych),
- **opisujące zachowania zakupowe i lojalność** (liczba różnych kupowanych marek, liczba kolejnych zakupów tej samej marki, liczba transakcji, całkowity wolumen zakupów, łączna wartość zakupów, średnia cena zakupu, udział zakupów dokonanych bez promocji, udział zakupów dokonanych w różnych promocjach),
- **motywacyjne i preferencje zakupowe** (udział zakupów przypadający na różne kategorie cenowe, udział zakupów ze względu na powód wyboru produktu – np. cena, zapach, jakość – oraz udział procentowy zakupów przypadający na konkretne marki).

Przygotowanie danych

Po usunięciu pierwszych wierszy technicznych oraz zbędnych spacji w nazwach kolumn, sprawdzono kompletność danych:

- **Braki danych** występowały w niemal wszystkich kolumnach, ale nie przekraczały 2 rekordów na zmienną.
- **Liczba zduplikowanych obserwacji** wynosiła 0, co potwierdza unikalność danych gospodarstw.

Po konwersji zmiennych do typu numerycznego, usunięto obserwacje zawierające braki.

Statystyki opisowe:

	count	mean	std	min	25%	50%	75%	max	CV	Skewness	Kurtosis
1											
No. of Brands	600.0	3.637	1.580	1.000	2.000	3.000	5.000	9.000	0.434	0.520	-0.104
Brand Runs	600.0	15.752	10.396	1.000	8.000	15.000	21.000	74.000	0.660	1.324	3.626
Total Volume	600.0	11914.770	7770.375	150.000	6825.000	10360.000	15343.750	50895.000	0.652	1.450	3.530
No. of Trans	600.0	31.153	17.427	1.000	22.000	28.000	40.000	138.000	0.559	1.265	4.035
Value	600.0	1337.386	883.155	20.000	789.562	1216.000	1675.750	6371.850	0.660	1.870	6.595
Trans / Brand Runs	600.0	2.618	2.605	1.000	1.420	1.843	2.689	23.000	0.995	4.659	28.074
Vol/Tran	600.0	415.051	248.761	94.431	250.513	361.525	490.885	2525.000	0.599	2.633	12.535
Avg. Price	600.0	11.835	3.743	5.624	9.762	11.250	13.421	33.325	0.316	1.301	3.922
Pur Vol No Promo - %	600.0	0.913	0.119	0.000	0.879	0.953	1.000	1.000	0.131	-2.500	9.296
Pur Vol Promo 6 %	600.0	0.054	0.093	0.000	0.000	0.000	0.068	0.667	1.738	2.818	10.089
Pur Vol Other Promo %	600.0	0.033	0.072	0.000	0.000	0.000	0.044	1.000	2.149	5.987	60.666

- **Prawie wszystkie zmienne wykazują skośność dodatnią**, co oznacza, że rozkład jest przesunięty w lewo – znaczna część gospodarstw robi niewielkie zakupy, a tylko nieliczne – bardzo duże.
- **Wysoka kurtoza** szczególnie dla *Pur Vol Other Promo % i Trans, Brand Runs, Vol/Tran* wskazuje na **obecność wielu wartości odstających** – czyli część gospodarstw ma skrajne, nietypowe zachowania zakupowe.
- **Wskaźniki zmienności (CV)** sugerują, że największe zróżnicowanie dotyczy udziału zakupów promocyjnych (*Pur Vol Promo 6 %, Pur Vol Other Promo %*), co może być istotne w segmentacji klientów.
- **Średni wolumen zakupów** (*Total Volume* ≈ 11 915) i wartość *(Value* ≈ 1337) są dość wysokie, ale rozproszenie danych (wysokie odchylenie standardowe) sugeruje istotne różnice między klientami.
- **Średnia cena (***Avg. Price)* **jest dość stabilna**, co potwierdza niski współczynnik zmienności – większość konsumentów kupuje produkty w podobnym przedziale cenowym.

3. Opis zastosowanych metod wyboru liczby klastrów

W celu określenia optymalnej liczby klastrów w analizie skupień wykorzystano dwie metody: metodę łokcia oraz metodę indeksu sylwetki.

♦ **Metoda łokcia** polega na analizie zmienności wewnątrzklastrowej (tzw. *within-cluster sum of squares*, WSS) w zależności od liczby klastrów. Dla kolejnych wartości k obliczana jest **suma kwadratów odległości punktów od środku klastra**. Wartości te prezentuje się na wykresie, a następnie identyfikuje punkt załamania (tzw. „**łokieć**"). Uznaje się, że dalsze zwiększanie liczby klastrów powyżej tego punktu nie przynosi istotnej poprawy jakości grupowania.

♦ **Indeks sylwetki** mierzy jakość grupowania poprzez **porównanie odległości danego punktu od pozostałych punktów w tym samym klastrze oraz od punktów w najbliższym innym klastrze.** Dla każdego obiektu obliczany jest wskaźnik sylwetki S(i), a następnie uśredniany do postaci globalnego indeksu GSI (Global Silhouette Index).

Wartości indeksu mieszczą się w przedziale od -1 do 1. Im **wyższa wartość**, tym **lepsze dopasowanie** obiektów do klastrów:

o GSI > 0,70 – silna struktura grupowania o
0,50 < GSI ≤ 0,70 – poprawna struktura o
0,25 < GSI ≤ 0,50 – słaba struktura o GSI ≤
0,25 – brak wyraźnych skupień.

4. Opis zastosowanych metod grupowania

- **Grupowanie hierarchiczne – metoda Warda**

To metoda aglomeracyjna, która zaczyna od traktowania każdego obiektu jako oddzielnej grupy i łączy je krok po kroku w coraz większe klastry.
Kryterium Warda polega na wybieraniu takich par grup, których połączenie **najmniej zwiększa sumę kwadratów odległości** wewnątrz grup — czyli łączone są te klastry, których połączenie najmniej zwiększy **rozrzut wewnątrzgrupowy**.
Wyniki przedstawia się w postaci **dendrogramu**. Nie trzeba wcześniej ustalać liczby klastrów – wybiera się ją na podstawie przecięcia dendrogramu.

- **K-średnich z medoidami (k-medoids)**

To odmiana klasycznego algorytmu k-średnich, **bardziej odporna na wartości odstające i szum**.
Zamiast centroidów grupy reprezentowane są przez rzeczywiste obserwacje – tzw. **medoidy**, które są najbardziej „centralne" w swojej grupie.

Główna różnica między K-means a K-medoids polega na tym, że K-means używa wyłącznie **odległości euklidesowej**, natomiast K-medoids może działać na **dowolnej macierzy odległości** (nawet niesymetrycznej).
K-medoids minimalizuje **sumę niepodobieństw pomiędzy parami punktów**, a nie sumę kwadratów odległości – jak K-means.

- **Sieci Kohonena**

Grupa **sieci neuronowych uczących się w sposób samoorganizujący i konkurencyjny**. Na wejście podawany jest wektor danych, a neurony „rywalizują" – wygrywa ten, który **najlepiej pasuje do danego sygnału**.
Uczenie polega na **dostosowywaniu wag** zwycięskiego neuronu oraz jego sąsiadów, co prowadzi do odwzorowania danych na **siatkę 2D** w sposób, który zachowuje strukturę podobieństw między obiektami.
Pozwala na intuicyjne, **wizualne rozpoznanie struktury klastrów** i ich wzajemnych relacji.
Wymaga wcześniejszego ustalenia liczby neuronów (= liczby grup).

5. Wyniki obliczeń

- **K-średnich z medoidami (k-medoids)**

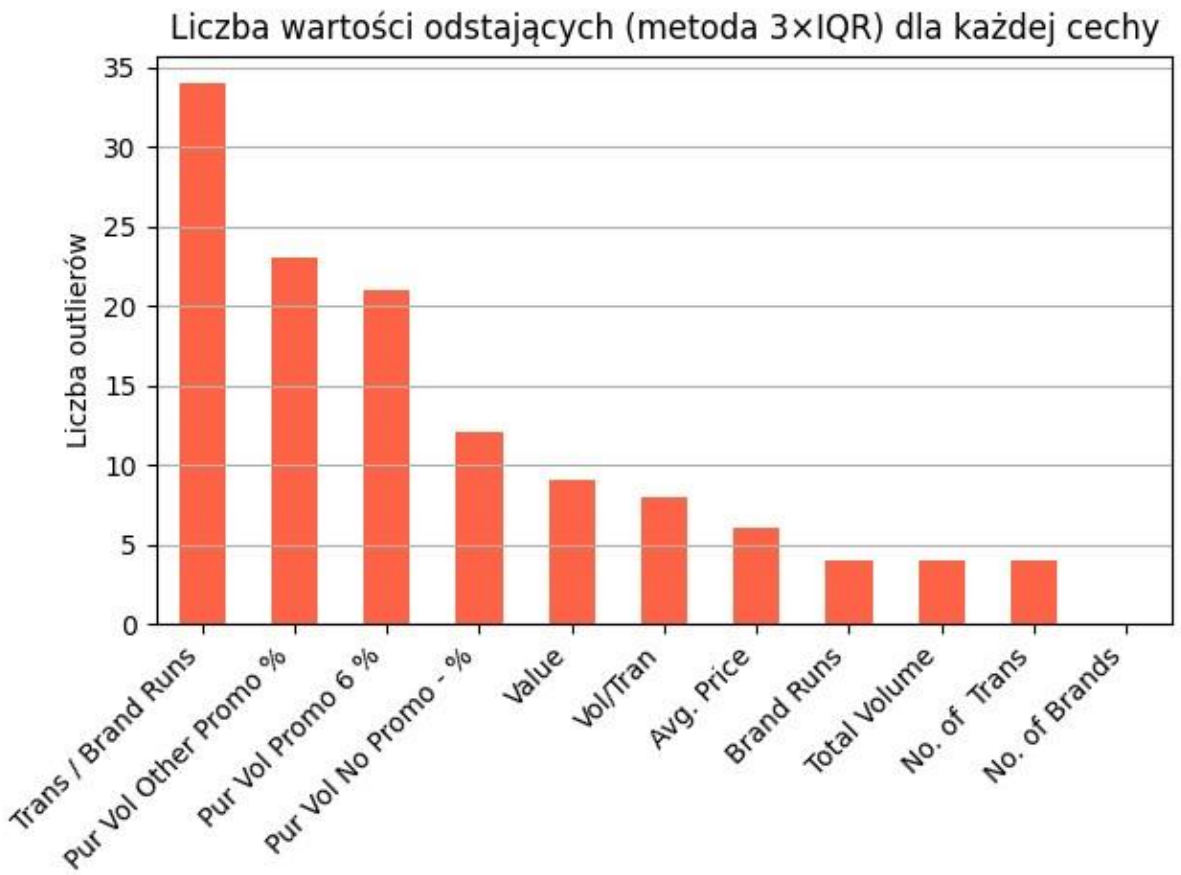

W analizie wykryto wartości odstające na poziomie do 6% w wybranych cechach (wg metody 3×IQR). Zamiast ich usuwania, zastosowano **metodę K-medoids** w celu ograniczenia ich wpływu na grupowanie.

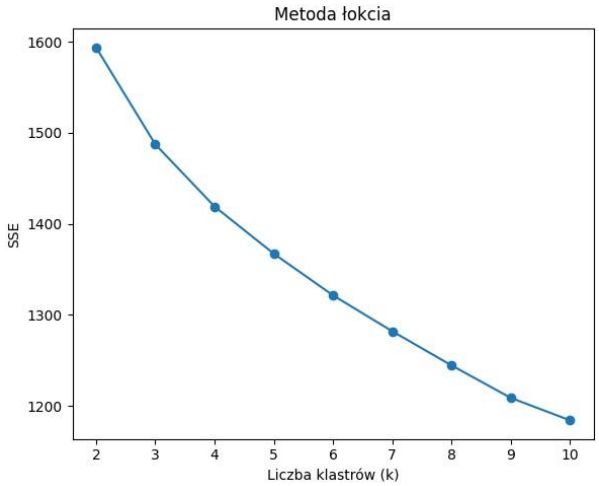

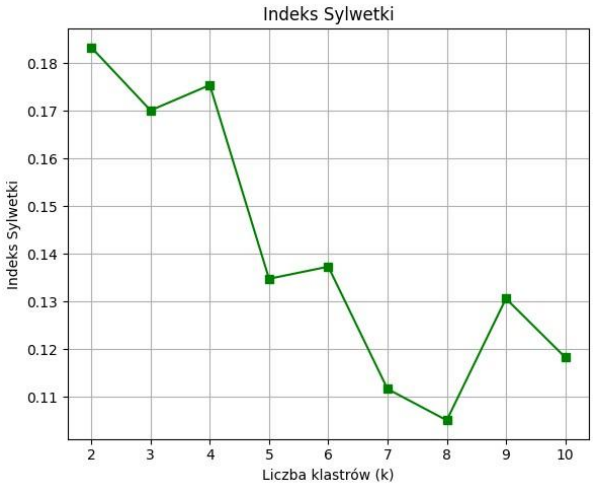

Analizując oba wykresy – **metodę łokcia oraz indeks sylwetki** (współczynnik Silhouette) – najlepszymi kandydatami są k = 4 lub k = 5. Choć przy k = 5 wartość indeksu sylwetki spada nieznacznie, to jednocześnie następuje znaczna redukcja błędu (SSE) względem 4. Z tego względu optymalnym wyborem pozostaje **5 klastrów**, jako kompromis między zwartą strukturą a dokładnością podziału.

Opis 5 klastrów:

KLASTER 0 (186) - *Umiarkowani użytkownicy*: średnia aktywność zakupowa (Trans = 26.7, Brands = 3.13) i wartość (Value = 1185.39).
Wysoka lojalność (No Promo = 92%), bardzo mało promocji (Promo 6% = 3%), kupują raczej drożej (Avg. Price = 13.38).

KLASTER 1 (59) - *Promocyjny segment*: przeciętna aktywność (Trans = 32), ale wysoka podatność na promocje (Promo 6% = 27%).
Niska lojalność (No Promo = 66%), średnia cena (Avg. Price = 13.21), wartość zakupów umiarkowana (Value = 1139.12).

KLASTER 2 (163) - *Najbardziej aktywni i lojalni klienci*: najwyższa liczba marek (5.27), transakcji (46.39) i wysoka wartość zakupów (1552.15).
Bardzo lojalni (No Promo = 93%), promocje marginalne (Promo 6% = 5%), kupują w dobrej cenie (Avg. Price = 11.83).

KLASTER 3 (65) - *Masowi, lojalni kupujący o wysokim wolumenie* (Volume = 27 589) i najwyższej wartości (Value = 2837.56).
Lojalni (No Promo = 94%), mało promocji (Promo 6% = 3%), najniższa cena zakupu (Avg. Price = 10.15).

KLASTER 4 (127) - *Najmniej aktywni*: najniższa liczba marek (2.24) i transakcji (14.85), niska wartość zakupów (608.66).
Bardzo lojalni (No Promo = 98%), praktycznie brak promocji (Promo 6% = 1%), kupują najtaniej (Avg. Price = 9.81).

Opis 5 klastrów pod względem Wieku, Płci oraz Statusu społeczno-ekonomicznego:

AGE = 1 — najmłodsi, AGE = 4 — najstarsi

- **Klaster 0:** 43% AGE 4, 33% AGE 3 – przewaga starszych i średnich grup wiekowych
- **Klaster 1:** 58% AGE 4 – dominują osoby starsze
- **Klaster 2:** 48% AGE 4, 28% AGE 3 – również przewaga starszych
- **Klaster 3:** 63% AGE 4 – zdecydowanie najstarszy segment
- **Klaster 4:** 28% AGE 2, 25% AGE 3, 43% AGE 4 – bardziej zrównoważony, ale najmłodszy w porównaniu z innymi

SEX = 0 — mężczyźni, SEX = 2 — kobiety, SEX = 1 — brak danych

- **Klaster 0:** 85% kobiet, 10% mężczyzn – silna przewaga kobiet
- **Klaster 1:** 93% kobiet, 5% mężczyzn – bardzo sfeminizowany
- **Klaster 2:** 91% kobiet – również bardzo sfeminizowany
- **Klaster 3:** 98% kobiet – niemal wyłącznie kobiety
- **Klaster 4:** 66% kobiet, 33% mężczyzn – bardziej zrównoważony, ale kobiety nadal dominują

SEC = 1 — najwyższy status społeczno-ekonomiczny, SEC = 4 — najniższy

- **Klaster 0:** zrównoważony – 27% SEC 1, 25% SEC 2, 26% SEC 3
- **Klaster 1:** przewaga wyższego statusu – 34% SEC 1, 37% SEC 2
- **Klaster 2:** mieszany – po ok. 25–30% w każdej kategorii
- **Klaster 3:** niższe warstwy – 31% SEC 3, 34% SEC 4
- **Klaster 4:** najniższy status – 36% SEC 4, 26% SEC 3

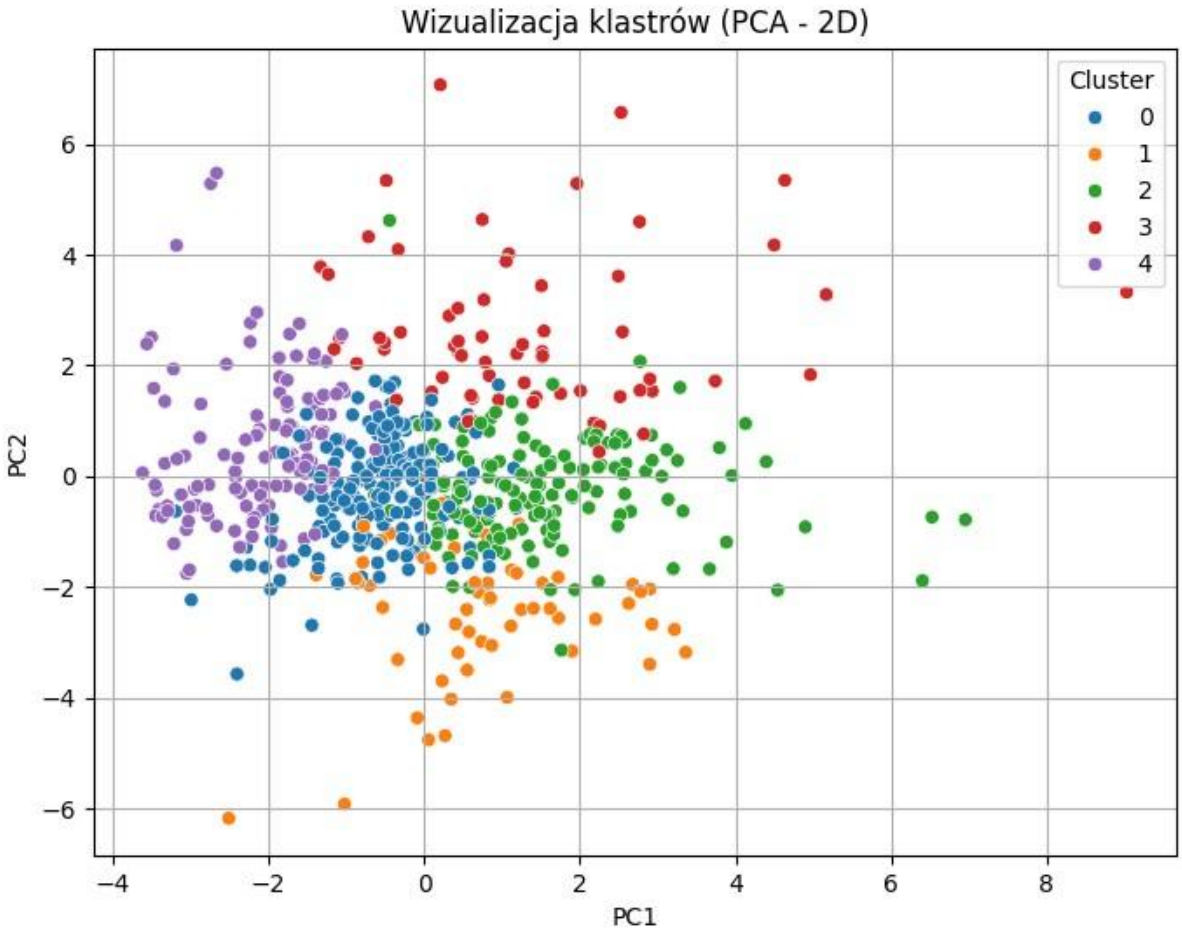

Wizualizacja potwierdza, że podział na **5 klastrów dobrze odwzorowuje zróżnicowanie w danych**. Klastry różnią się zarówno rozmiarem, jak i rozproszeniem — co może wskazywać na różne typy zachowań konsumenckich i potencjały marketingowe.

o **Grupowanie hierarchiczne – metoda Warda**

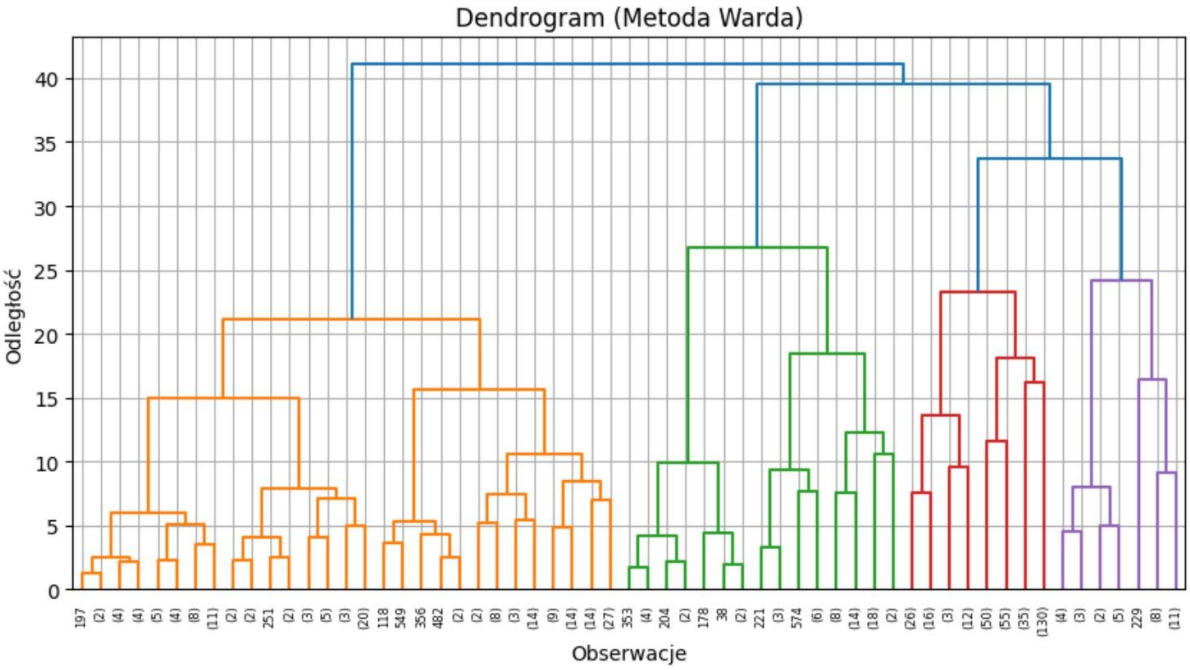

Powyższy dendrogram wskazuje na liczbę klastrów równą 4, dlatego do tej metody grupowania, czyli hierarchicznej użyto właśnie **4 klastrów**.

Opis 4 klastrów:

KLASTER 0 (65) – *Masowi lojalni kupujący*: najwyższa wartość zakupów (Value = 2457.18) i bardzo wysoki wolumen (Volume = 25 190).
Wysoka aktywność (Trans = 31.18), ale niewielka liczba marek (Brands = 2.86).
Bardzo lojalni (No Promo = 96%), promocje rzadko (Promo 6% = 2%), kupują najtaniej (Avg. Price = 9.32).

KLASTER 1 (327) – *Umiarkowani użytkownicy*: najliczniejszy segment, średnia aktywność (Trans = 24.35), średnia liczba marek (Brands = 3.01), umiarkowana wartość zakupów (Value = 1026.21).
Wysoka lojalność (No Promo = 95%), bardzo rzadkie promocje (Promo 6% = 3%). Kupują stosunkowo drogo (Avg. Price = 12.06), ale bez silnego wpływu promocji.

KLASTER 2 (34) – *szukający promocji*: najmniejszy segment, niska aktywność (Trans = 19.97), niska wartość zakupów (Value = 868.53).
Liczba marek przeciętna (Brands = 2.97), najniższa lojalność (No Promo = 59%), bardzo wysoka podatność na promocje (Promo 6% = 22%, inne = 19%). Kupują najdrożej (Avg. Price = 12.27), wrażliwi na oferty.

KLASTER 3 (174) – *Aktywni i różnorodni*: najwyższa liczba transakcji (Trans = 46.11), najwięcej marek (Brands = 5.23), wysoka wartość (Value = 1595.48).
Lojalność umiarkowana (No Promo = 89%), korzystają z promocji (Promo 6% = 8%). Kupują dość drogo (Avg. Price = 12.27), to klienci otwarci na różnorodność marek.

Opis 4 klastrów pod względem Wieku, Płci oraz Statusu społeczno-ekonomicznego:

AGE = 1 — najmłodsi, AGE = 4 — najstarsi

- **Klaster 0**: 65% AGE 4, 23% AGE 3 – zdecydowanie najstarszy segment
- **Klaster 1**: 43% AGE 4, 30% AGE 3, 24% AGE 2 – bardziej zróżnicowany, ale starszy dominuje
- **Klaster 2**: 35% AGE 3, 35% AGE 4, 24% AGE 2 – segment dojrzały, ale nieco młodszy niż pozostałe
- **Klaster 3**: 52% AGE 4, 25% AGE 3, 20% AGE 2 – starsi, ale też aktywni

SEX = 0 — mężczyźni, SEX = 2 — kobiety, SEX = 1 — brak danych

- **Klaster 0**: 98% kobiet, 2% mężczyzn – zdecydowana przewaga kobiet
- **Klaster 1**: 80% kobiet, 16% mężczyzn – sfeminizowany, ale bardziej zrównoważony
- **Klaster 2**: 71% kobiet, 29% mężczyzn – najbardziej męski segment
- **Klaster 3**: 93% kobiet, 3% mężczyzn – wyraźna dominacja kobiet

SEC = 1 — najwyższy status społeczno-ekonomiczny, SEC = 4 — najniższy

- **Klaster 0**: raczej niższe warstwy – 32% SEC 3, 34% SEC 4
- **Klaster 1**: zróżnicowany – 26% SEC 1, 22% SEC 2, 24% SEC 3, 27% SEC 4
- **Klaster 2**: bardziej zamożni – 21% SEC 1, 38% SEC 2, tylko 24% SEC 4
- **Klaster 3**: przeciętny – 26% SEC 1, 31% SEC 2, 25% SEC 3, tylko 18% SEC 4

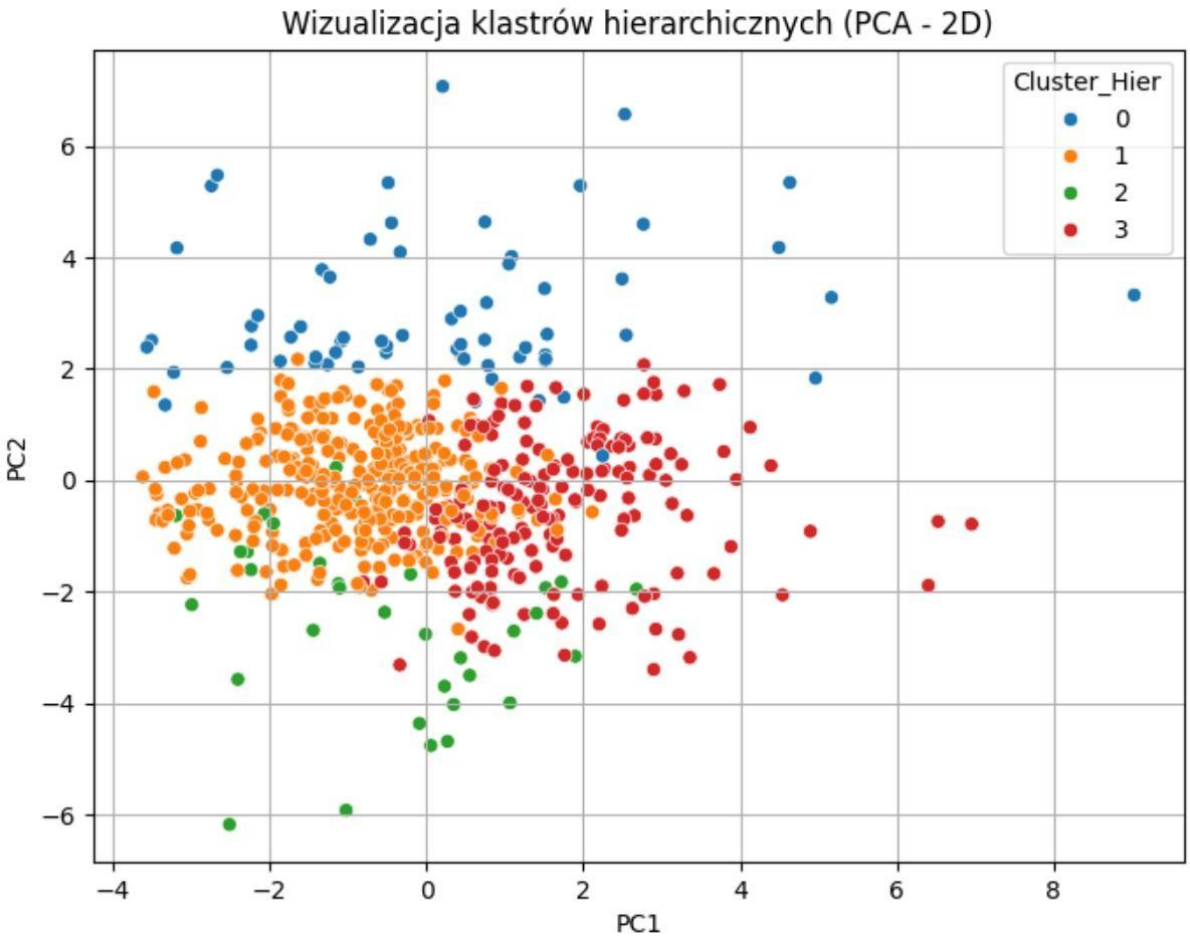

Wizualizacja PCA dla klasteryzacji hierarchicznej pokazuje wyraźny podział gospodarstw na odrębne grupy. Klastry tworzą zauważalne skupiska, jednak w niektórych miejscach punkty nachodzą na siebie, szczególnie między klastrami 1 i 3. Sugeruje to częściowe podobieństwo między tymi segmentami.

- **Sieci Kohonena**

W celu wybrania optymalnej liczby klastrów dla tej metody posłużono się trzema metrykami jakości klasteryzacji:

1. **Silhouette Score**

Miara spójności klastrów — porównuje średnią odległość wewnątrz klastra do średniej odległości do najbliższego innego klastra.

Im wyższa wartość, tym lepiej (lepsze rozdzielenie klastrów). Wartości powyżej 0.25 uznaje się za umiarkowane, a powyżej 0.5 za bardzo dobre. W przypadku analizowanych danych niestety każda macierz miała wartość poniżej 0.2 (zakres wartości: od –1 do 1.).

2. **Calinski–Harabasz Index**

Mierzy stosunek rozproszenia między klastrami do rozproszenia wewnątrz klastrów.

Im wyższa wartość, tym lepsze rozdzielenie i zwartość klastrów. Jest wrażliwy na liczbę klastrów – często rośnie przy większej liczbie segmentów.

3. **Davies–Bouldin Index**

Mierzy średnie podobieństwo między klastrami, uwzględniając ich rozmiar i odległość.

Im niższy wynik, tym lepiej (klastry są bardziej zwarte i dobrze odseparowane). Wartości poniżej 1.5 są zazwyczaj akceptowalne, a im bliżej 0, tym lepszy podział.

Wyniki analizowanych siatek prezentują się następująco:

	Grid	Clusters	Silhouette	Calinski-Harabasz	Davies-Bouldin
0	2x2	4	0.185	111.8	1.483
3	4x1	4	0.181	105.8	1.603
1	3x1	3	0.175	109.7	1.672
4	4x2	8	0.168	101.5	1.346
2	3x2	6	0.152	101.9	1.509

Najlepszy wynik uzyskano dla **siatki 2x2** — najwyższy Silhouette score (0.185) i CalinskiHarabasz (111.8), co wskazuje na najbardziej spójne i dobrze rozdzielone klastry. Siatka 4x2 osiągnęła najniższy Davies-Bouldin (1.346), lecz przy większej liczbie klastrów. Drugi w kolejności niski wynik Davies-Bouldin (1.483) miała siatka 2x2 i to ona ostatecznie wydaje się być najkorzystniejszym kompromisem między liczbą klastrów a jakością podziału. Dlatego w analizie z wykorzystaniem sieci Kohonena zdecydowano się na siatkę 2x2, a więc liczbę klastrów = 4.

Opis 4 klastrów:

KLASTER 0 (250) – *Umiarkowani i lojalni:* Niska liczba marek (2.81), przeciętna liczba transakcji (20.3), najniższa wartość zakupów (856.60). Wysoka lojalność (No Promo = 96%), bardzo mało promocji (Promo 6% = 2%). Dość wysoka cena zakupu (Avg. Price = 12.39).

KLASTER 1 (110) – *Masowi, lojalni i bardzo wartościowi:* Duży wolumen (23 008), wysoka liczba transakcji (33.1), najwyższa wartość zakupów (2280.42). Lojalność bardzo wysoka (No Promo = 95%), promocje marginalne. Najniższa średnia cena zakupu (Avg. Price = 9.76).

KLASTER 2 (83) – *Promocyjny segment*: Umiarkowana aktywność (Trans = 28.3), przeciętna wartość zakupów (1014.97). Najniższa lojalność (No Promo = 69%), najwyższy udział promocji (Promo 6% = 21%). Średnia cena (Avg. Price = 11.82).
KLASTER 3 (157) – *Najbardziej aktywni:* Najwyższa liczba marek (5.19), największa aktywność (Trans = 48.6), wysoka wartość zakupów (1612.68). Wysoka lojalność (No Promo

= 92%), niskie wykorzystanie promocji (Promo 6% = 5%). Najdrożej kupujący (Avg. Price = 12.41).

Opis 4 klastrów pod względem Wieku, Płci oraz Statusu społeczno-ekonomicznego:

AGE = 1 — najmłodsi, AGE = 4 — najstarsi

- **Klaster 0**: 43% AGE 4, 28% AGE 3, 26% AGE 2 – zrównoważony wiekowo, ale dominują starsi
- **Klaster 1**: 54% AGE 4, 28% AGE 3, 14% AGE 2 – zdecydowanie najstarszy segment
- **Klaster 2**: 52% AGE 4, 27% AGE 3, 19% AGE 2 – starsi, ale bardziej aktywni
- **Klaster 3**: 49% AGE 4, 29% AGE 3, 20% AGE 2 – segment dojrzały, z przewagą starszych

SEX = 0 — mężczyźni, SEX = 2 — kobiety, SEX = 1 — brak danych

- **Klaster 0**: 76% kobiet, 22% mężczyzn – bardziej zrównoważony, choć kobiety dominują
- **Klaster 1**: 95% kobiet, 2% mężczyzn – najmocniej sfeminizowany
- **Klaster 2**: 88% kobiet, 10% mężczyzn – również bardzo sfeminizowany
- **Klaster 3**: 92% kobiet, 3% mężczyzn – wyraźna dominacja kobiet

SEC = 1 — najwyższy status społeczno-ekonomiczny, SEC = 4 — najniższy

- **Klaster 0**: zrównoważony – 30% SEC 1, 24% SEC 3, 24% SEC 4
- **Klaster 1**: raczej niższe warstwy – 40% SEC 4, 28% SEC 3, tylko 13% SEC 1
- **Klaster 2**: umiarkowany – 25% SEC 1, 30% SEC 2, 23% SEC 4
- **Klaster 3**: przeciętny – 25% SEC 1, 31% SEC 2, 26% SEC 3, 18% SEC 4

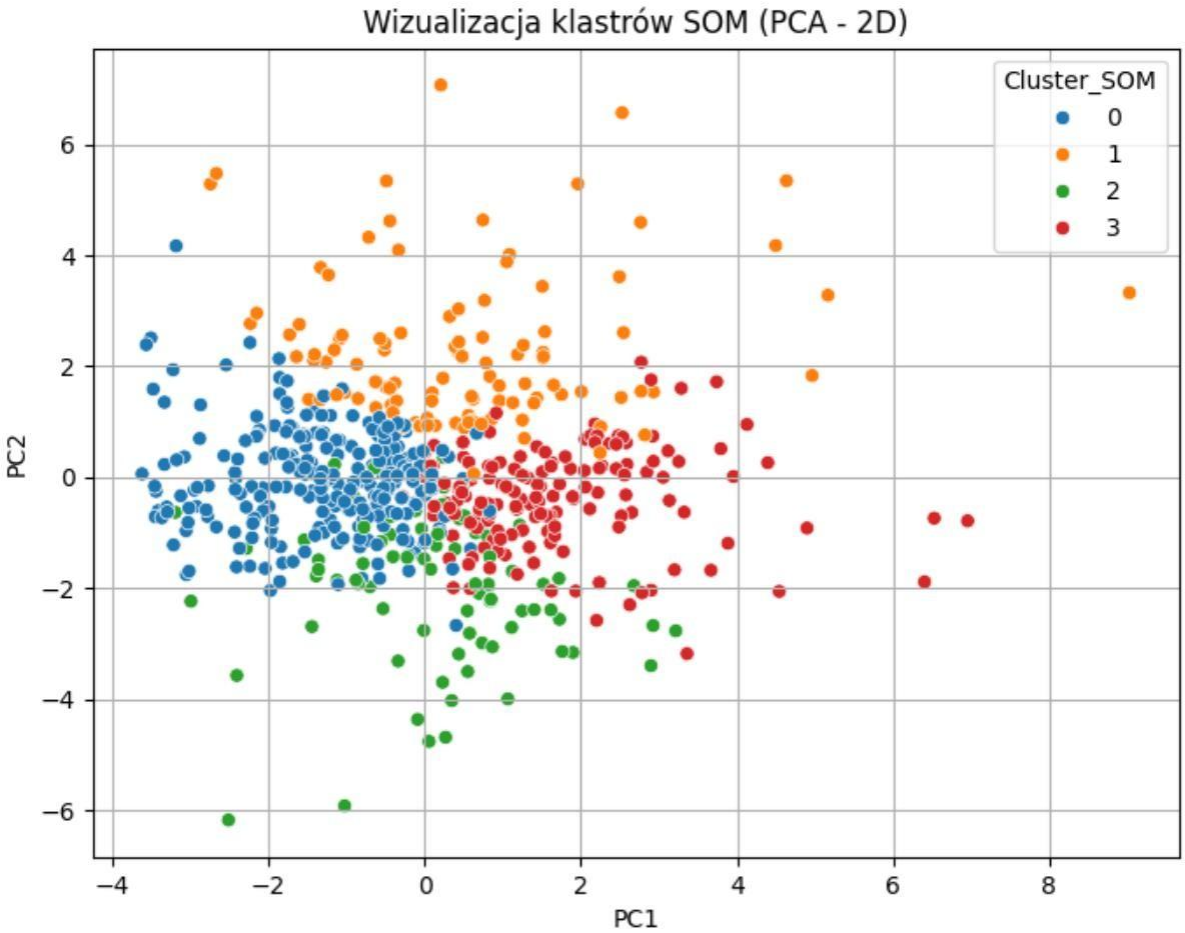

Wizualizacja klastrów uzyskanych metodą Kohonena (SOM 2x2) wskazuje na zauważalny podział obserwacji pomiędzy grupami. Pomimo wyraźnych centrów skupień, częściowe nachodzenie się punktów granicznych wskazuje na umiarkowaną separację – niektóre klastry mają cechy wspólne, co może wynikać z podobnych wzorców zakupowych.

6. Wnioski

W celu wybrania najlepszej metody klasteryzacji dla analizowanych danych wykorzystano te same metryki jakości, które wcześniej posłużyły do wyboru optymalnej wielkości siatki dla sieci Kohonena.

Poniżej przedstawiono tabelę z wynikami:

	Metoda	Silhouette	Calinski-Harabasz	Davies-Bouldin
0	KMedoids (k=5)	0.135	96.7	1.773
1	Hierarchiczne (Ward, k=4)	0.187	99.2	1.551
2	Sieć Kohonena (2x2)	0.185	111.8	1.483

Najlepszy wynik Silhouette uzyskała **metoda hierarchiczna (0.187)**. Druga w kolejności jest **sieć Kohonena (0.185)**. Niestety obie wartości są poniżej 0.2, co wskazuje na stosunkowo niewielkie odseparowanie klastrów — jednakże jest to typowe w przypadku danych o złożonej strukturze behawioralnej (widoczne jest to również na wykresach PCA).

Najwyższy Calinski-Harabasz osiągnęła **sieć Kohonena (111.8)**, co oznacza największe zróżnicowanie między klastrami przy relatywnie małym rozrzucie wewnątrz.

Najniższy Davies-Bouldin również uzyskała **SOM (1.483)**, co dodatkowo potwierdza jej przewagę w jakości podziału.

Wnioskując **sieć Kohonena prezentuje najlepszy kompromis jakościowy między wewnętrzną spójnością a separacją grup** i może być uznana za najbardziej efektywną metodę klasteryzacji w tym przypadku.

Analizując demografię:

- wszystkie metody klasteryzacji potwierdzają dużą **dominację kobiet w próbie** – większość respondentów to kobiety (w niektórych klastrach aż 95–98%).
- największy udział wiekowy to osoby w grupie **AGE_4 (najstarsi)** – w klastrach najbardziej lojalnych i aktywnych często dominują osoby starsze, co może świadczyć o stabilnych nawykach zakupowych.
- **zróżnicowanie statusu społeczno-ekonomicznego (SEC) jest widoczne** – niektóre klastry (np. SOM – klaster 1) zawierają osoby z niższych warstw (40% SEC_4), natomiast inne (np. SOM – klaster 3) są bardziej zamożne.

Zastosowanie trzech metod pozwoliło uzyskać spójny obraz segmentacji konsumentów. Niezależnie od metody można wyróżnić segmenty lojalnych i aktywnych klientów, segmenty promocyjne (wrażliwe na oferty specjalne), jak i grupy mniej zaangażowanych nabywców. Sieć Kohonena (SOM) wydaje się najskuteczniejsza pod względem jakości klasteryzacji, ale wszystkie metody dają porównywalnie dobre wyniki i prowadzą do podobnych wniosków.

7. Źródła:

- Skuteczne metody doboru optymalnej liczby klastrów
- Ściągawka do implementacji 7 metod wyboru optymalnej liczby klastrów w Pythonie
- K Medoids Clustering from Scratch in Python - DataQoil
- Sieci neuronowe - Klasyfikator Kohonena